

2019年NLP领域回顾

原文标题: NLP Year in Review — 2019

原文作者: Elvis Saravia

原文链接: <https://medium.com/dair-ai/nlp-year-in-review-2019-fb8d523bcb19>

以下为中文翻译:

2019年是NLP领域让人非常印象深刻的一年。在本文中,我想要分享在2019年在机器学习和NLP领域最重要的亮点。我主要关注NLP领域,但是我也将重点介绍一些与AI相关的有趣故事。标题没有进行特定的排序。文章可能包含出版物、工程工作、年度报告、发布的教育资源等等。

提醒~文章非常长,所以在你开始阅读之前,建议将本文章收藏。已经在文末分享了本文的PDF版本。

目录

- 出版物
- ML/NLP创新与社会
- ML/NLP工具与数据集
- 文章与博客
- 人工智能伦理
- ML/NLP教育

出版物

- 谷歌AI团队发布了[ALBERT](#),它是[BERT](#)的精简版本,用于自监督学习上下文语言表示。主要的提升是减少了冗余并更有效地分配模型的容量。该方法提高了12个NLP任务的最佳性能。

ALBERT: A LITE BERT FOR SELF-SUPERVISED LEARNING OF LANGUAGE REPRESENTATIONS

<https://arxiv.org/pdf/1909.11942.pdf>

<https://ai.googleblog.com/2019/12/albert-lite-bert-for-self-supervised.html>

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

<https://arxiv.org/abs/1810.04805>

- 今年早些时候, NVIDIA的研究人员发表了一篇[知名论文](#) (coined StyleGAN), 提出了一种用于GAN的替代生成器架构, 用于风格迁移 ([style transfer](#))。这是[后续工作](#), 其中重点在于改进, 例如重新设计生成器归一化过程。

A Style-Based Generator Architecture for Generative Adversarial Networks

<https://arxiv.org/pdf/1812.04948.pdf>

Analyzing and Improving the Image Quality of StyleGAN



Our configuration F — generated images



Our configuration F — real images

上排显示目标图像，下排显示合成图像。-- [源论文](#)

- 今年我最喜欢的论文之一是[code2seq](#)，这是一种从结构化代码表示中生成自然语言序列的方法。这样的研究可以应用自动化代码摘要和文档之类的任务。

CODE2SEQ: GENERATING SEQUENCES FROM STRUCTURED REPRESENTATIONS OF CODE

<https://code2seq.org/>

<https://openreview.net/pdf?id=H1gKY09tX>

- 曾经想过是否有可能从生物医学文本挖掘训练一个生物医学语言模型？答案是[BioBERT](#)，这是一种用于从生物医学文献中抽取重要信息的上下文方法。

BioBERT: a pre-trained biomedical language representation model for biomedical text mining

<https://arxiv.org/abs/1901.08746>

- 在BERT发布后，Facebook研究人员发表了[RoBERTa](#)，一种优化提升BERT的新方法，并在各种NLP基准测试上取得最优结果。

RoBERTa: A Robustly Optimized BERT Pretraining Approach

<https://ai.facebook.com/blog/roberta-an-optimized-method-for-pretraining-self-supervised-nlp-systems/>

<https://arxiv.org/abs/1907.11692>

- 来自Facebook AI的研究人员最近也发表了基于all-attention层的[方法](#)来提升Transformer语言模型的效率。这个研究组的更多工作包含一种[方法](#)来教AI系统如何使用自然语言进行规划。

Augmenting Self-attention with Persistent Memory

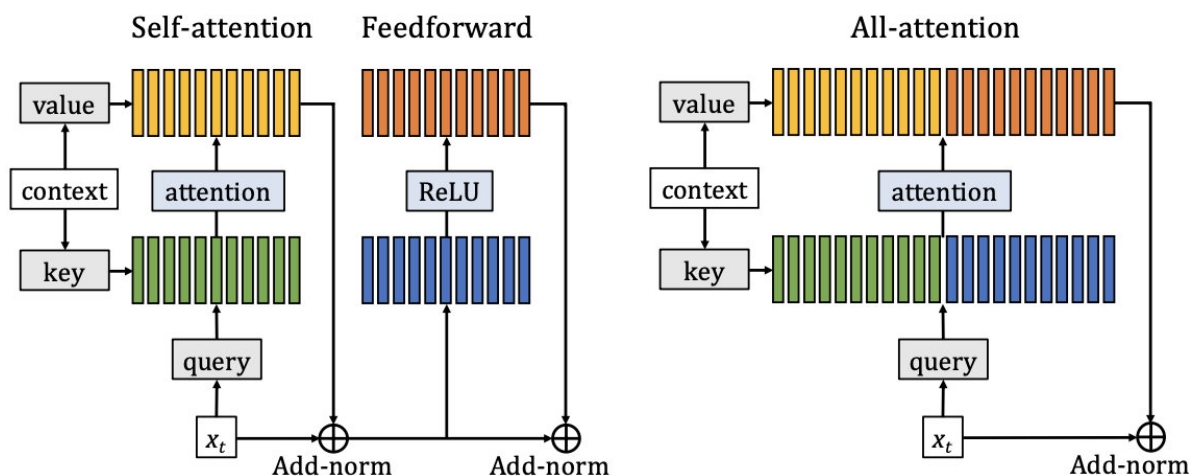
<https://ai.facebook.com/blog/making-transformer-networks-simpler-and-more-efficient/>

<https://arxiv.org/pdf/1907.01470.pdf>

Hierarchical Decision Making by Generating and Following Natural Language Instructions

<https://ai.facebook.com/blog/teaching-ai-to-plan-using-language-in-a-new-open-source-strategy-game/>

<https://arxiv.org/abs/1906.00744>



all-attention层 -- [原论文](#)

- 可解释性仍然是ML和NLP领域重要的主题。这篇[论文](#)提供了有关可解释性、分类规则和未来研究机会的工作的全面概述。

Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI

<https://arxiv.org/abs/1910.10045>

- Sebastian Ruder发表了他关于自然语言处理的神经网络迁移学习的[论文](#)。

Neural Transfer Learning for Natural Language Processing

<https://ruder.io/thesis/>

https://ruder.io/thesis/neural_transfer_learning_for_nlp.pdf

- 一组研究人员开发一种方法用于对话上下文中进行情感识别。这种方法可以为情感对话生成铺平道路。另外一个相关工作是被称为[DialogueGCN](#)的GNN方法，被用来检测对话中的情绪。这项研究论文也提供了[代码实现](#)。

DialogueGCN: A Graph Convolutional Neural Network for Emotion Recognition in Conversation

<https://www.aclweb.org/anthology/D19-1015.pdf>

<https://github.com/SenticNet/conv-emotion/tree/master/DialogueGCN>

- 谷歌AI Quantum团队在《自然》杂志上发表了一篇论文，声称他们已经开发出了一种量子计算机，这种计算机比世界最大的超级计算机还要快。阅读他们的实验了解[更多](#)。

Quantum supremacy using a programmable superconducting processor

<https://ai.googleblog.com/2019/10/quantum-supremacy-using-programmable.html>

<https://www.nature.com/articles/s41586-019-1666-5>

- 如前所述，神经网络架构最需要大量改进的领域之一就是可解释性。该[论文](#)讨论了注意力的局限性，这种在上下文语言模型中进行解释的可靠方法。

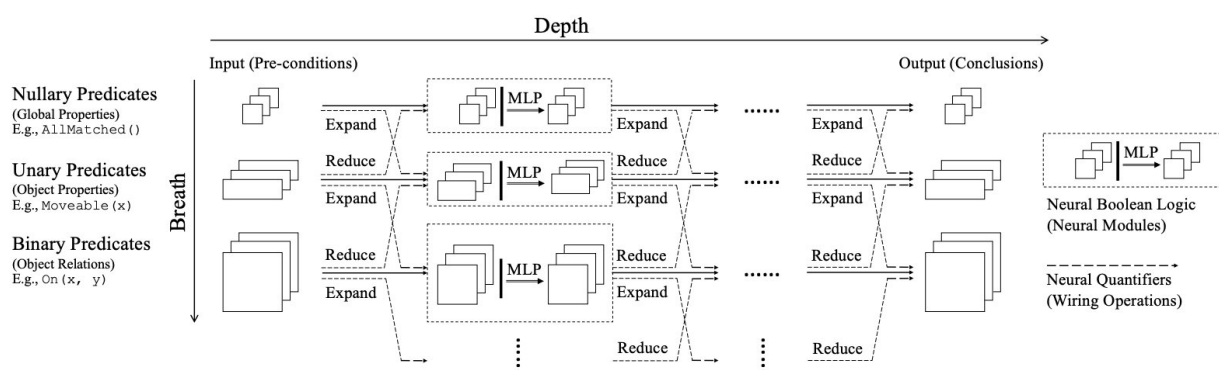
Attention is not Explanation

<https://arxiv.org/abs/1908.04626>

- [神经逻辑机](#)是一种神经-符号网络架构，它能够在归纳学习和逻辑推理方面做得很好。该模型在排序数组和寻找最短路径之类的任务上表现出色。

Neural Logic Machines

<https://arxiv.org/abs/1904.11694>



神经逻辑机架构 -- [原论文](#)

- 这篇[论文](#)应用Transformer语言模型来抽取式和摘要式的神经网络文档摘要。

On Extractive and Abstractive Neural Document Summarization with Transformer Language Models

<https://arxiv.org/abs/1909.03186>

- 研究人员开发了一种方法，其聚焦于使用比较来构建和训练ML模型。不需要大量的特征标签对，这种[技术](#)将图片与之前看到的图像进行比较来决定图片是否应该具有特定标签。

Building Machine Learning Models via Comparisons

<https://blog.ml.cmu.edu/2019/03/29/building-machine-learning-models-via-comparisons/>

- Nelson Liu和其他人发表了一篇[论文](#)，讨论了诸如BERT和ELMo之类的经过预训练的contextualizers所捕获的语言知识的类型。

Linguistic Knowledge and Transferability of Contextual Representations

<https://arxiv.org/abs/1903.08855>

- [XLNet](#)是一种NLP预训练方法，该方法在20种任务中取得了提升，超过了BERT。我曾写过关于这个出色工作的[总结](#)。

XLNet: Generalized Autoregressive Pretraining for Language Understanding

<https://arxiv.org/abs/1906.08237>

<https://medium.com/dair-ai/xlnet-outperforms-bert-on-several-nlp-tasks-9ec867bb563b>

- Deepmind的这项[工作](#)报告了一项广泛的经验研究的结果，该研究旨在评估适用于各种任务的语言理解模型。这种广泛的分析对于更好地理解语言模型捕获的内容以提高其效率非常重要。

Learning and Evaluating General Linguistic Intelligence

<https://arxiv.org/abs/1901.11373>

- [VisualBERT](#)是用于建模视觉和语言任务（包括VQA和Flickr30K等）的简单而鲁棒的框架。这种方法利用了Transformer层的堆栈以及自注意，以对齐一段文本和图像区域中的元素。

VisualBERT: A Simple and Performant Baseline for Vision and Language

<https://arxiv.org/abs/1908.03557>

- 这项[工作](#)提供了详细的分析，比较了NLP迁移学习方法，撰写了NLP从业人员指南。

To Tune or Not to Tune? Adapting Pretrained Representations to Diverse Tasks

<https://arxiv.org/abs/1903.05987>

- Alex Wang和Kyunghyun提出了[BERT的实现方法](#)，它能够产生高质量、流畅的世代。这是一个Colab [notebook](#)可以进行尝试。

BERT has a Mouth, and It Must Speak: BERT as a Markov Random Field Language Model

<https://arxiv.org/abs/1902.04094>

<https://colab.research.google.com/drive/1MxKZGtQ9SSBjTK5ArsZ5LKhkztzg52RV>

- Facebook研究人员发布了XLM的代码（[PyTorch实现](#)），该代码是用于跨语言模型预训练的模型。

Cross-lingual Language Model Pretraining

<https://arxiv.org/abs/1901.07291>

<https://github.com/facebookresearch/XLM>

- 这项[工作](#)对强化学习算法在神经机器翻译中的应用提供了全面的分析。

RL in NMT: the Good, the Bad and the Ugly

<https://www.cl.uni-heidelberg.de/statnlpgroup/blog/rl4nmt/>

- 这份发表在JAIR上的[综述](#)论文全面概述了跨语言单词嵌入模型的训练、评估和使用。

A Survey of Cross-lingual Word Embedding Models

<https://jair.org/index.php/jair/article/view/11640>

- Gradient发表了一篇出色的[文章](#)，详细介绍了强化学习的当前局限性，也为分层强化学习提供了一条可能的途径。并且适时地，几个人发布了一套出色的[教程](#)，以开始进行强化学习。

The Promise of Hierarchical Reinforcement Learning

<https://thegradient.pub/the-promise-of-hierarchical-reinforcement-learning/>

https://github.com/araffin/rl-tutorial-jnrr19/blob/master/1_getting_started.ipynb

- 本[论文](#)提供了上下文词表示的简要介绍。

Contextual Word Representations: A Contextual Introduction

<https://arxiv.org/abs/1902.06006>

ML/NLP创新与社会

机器学习已被应用来解决现实世界中的问题，但它也已经以有趣和创新的方式被应用。机器学习的创新与人工智能的任何其他研究领域一样重要，因为最终，我们希望构建能够帮助塑造我们的文化和社会的人工智能系统。

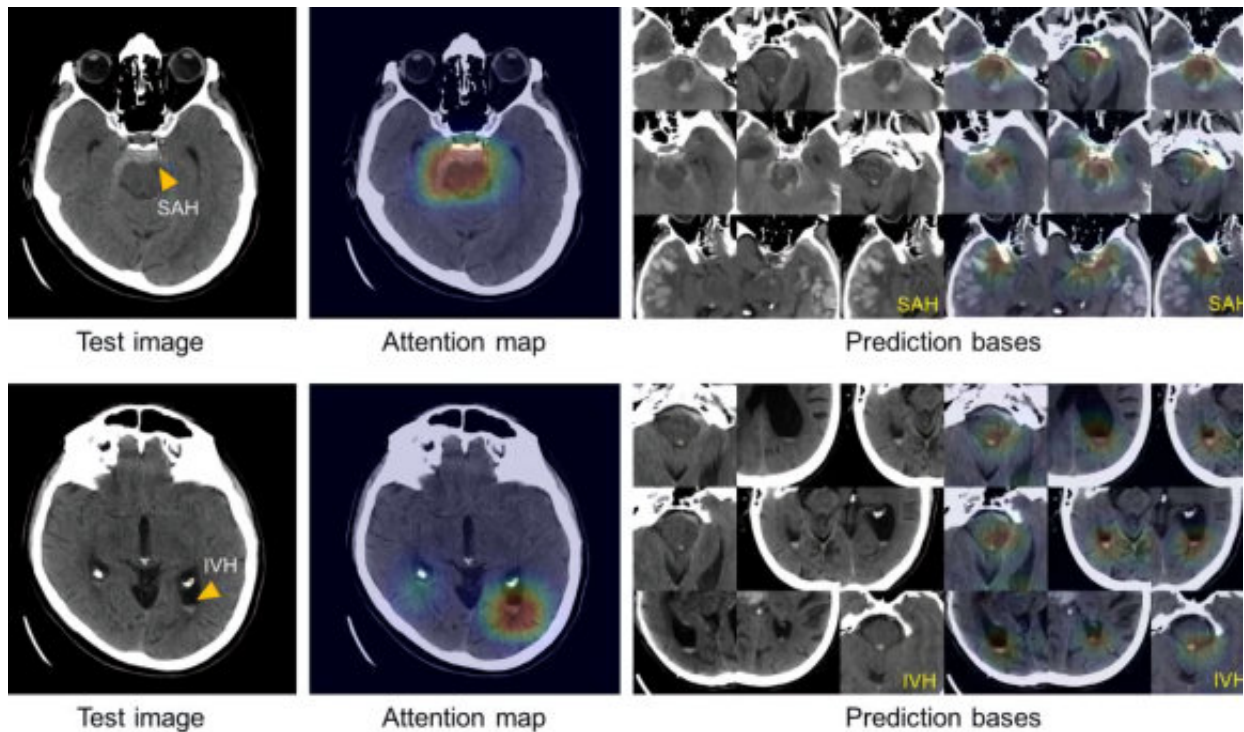
- 2019年底，Gary Marcus和Yoshua Bengio就深度学习、符号AI和混合AI系统进行了[辩论](#)。
- 斯坦福发布了[2019年AI指数报告](#)，该报告对AI的现状进行了全面的分析，可以用来更好地了解AI的总体进展。
- 常识推理（[Commonsense reasoning](#)）仍然是研究的重要领域，因为我们旨在构建人工智能系统，该系统不仅能够对所提供的数据做出预测，而且能够理解并能够推理出这些决策。此类技术可用于对话式AI，其目的是使智能体能够与人进行更自然的对话。在与Nasrin Mostafazadeh的[访谈](#)中查看有关常识性推理和讲故事和语言理解等应用的讨论。您还可以查看有关如何利用语言模型进行[常识推理](#)的最新文章。
- 激活图（[Activation Atlases](#)）是Google和Open AI的研究人员开发的一种技术，用于更好地理解可视化神经网络神经元之间发生的相互作用。



“InceptionV1 视觉分类网络的激活图揭示了许多完全实现的功能，例如电子设备，建筑物，食物，动物的耳朵，植物和水汪汪的背景。”-- [原网址](#)


- 观看由Geoffrey Hinton和Yann LeCun发表的图灵演讲 ([Turing Lecture](#))，他们与Yoshua Bengio一起获得了今年的图灵奖。
- 这篇[论文](#)讨论了通过机器学习应对气候变化。
- OpenAI发布了一份广泛的[报告](#)，讨论了语言模型的社会影响，涉及诸如技术的有益使用和潜在滥用之类的话题。
- 情感分析 (emotion analysis) 继续在各种应用中使用。[Mojifier](#)是一个很酷的项目，它可以查看图像，检测情感并用与检测到的情感匹配的表情符号替换面部。
- 利用人工智能技术进行放射学的工作在今年也很流行。这是一篇该研究领域中趋势和观点的不错[总结](#)。纽约大学的研究人员还发布了一个[基于Pytorch实现](#)的神经网络，可提高放射线医师在乳腺癌筛查中的表现。这是一个称为MIMIC-CXR的[主要数据集](#)，其中包含胸部X射线和文字放射学报告的数据库。
- 纽约时报为Karen Spark Jones写了一篇[文章](#)，以纪念她对NLP和Information Retrieval所做的开创性贡献。
- [OpenAI Five](#)成为第一个在电竞游戏中击败世界冠军的AI系统。

- [全球AI人才报告](#)提供了有关全球AI人才库和全球AI人才需求的详细报告。
- DeepMind团队提供了一个出色的[播客](#)，参与者可以在其中讨论与AI有关的最前沿的话题。在谈到AI的潜力时，Demis Hassabis接受了《经济学人》的[采访](#)，他谈到了一些未来派的想法，例如将AI用作人类思维的扩展，以潜在地找到重要科学问题的解决方案。
- 今年还见证了ML在医疗保健领域的惊人发展。例如，马萨诸塞州的研究人员开发了一种[AI系统](#)，该系统能够与人类一样准确地发现脑出血。



"由AI系统分析的脑部扫描。"

- Janelle Shane总结了一组[“怪异”的实验](#)，这些实验显示了如何以创造性的方式使用机器学习来进行有趣的实验。有时，这是真正了解AI系统实际上在做什么和不在做什么的实验。例如使用神经网络产生假蛇并讲笑话。



Snake Species

- 通过在TensorFlow之上构建的机器学习模型来[学习寻找行星](#)。
- OpenAI[讨论](#)了发布大规模无监督语言模型的意义（包括潜在的恶意用例）。
- 这个[Colab notebook](#)很好地介绍了如何使用Nucleus和TensorFlow进行“DNA序列错误校正”。这是一篇有关深度学习架构用于探索DNA的详细[文章](#)。

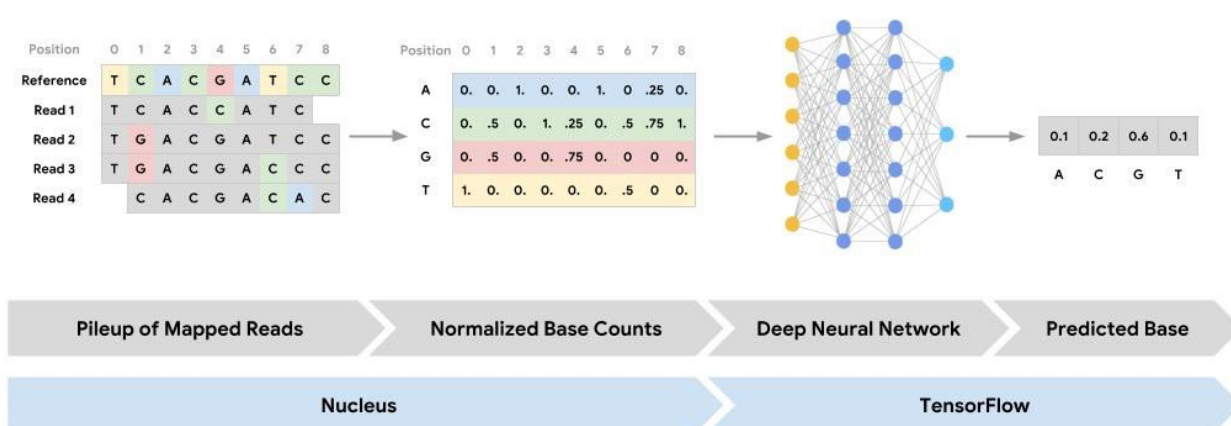


Figure 1: We formulate consensus-based DNA sequencing error correction as a multiclass classification problem. Using Nucleus, we construct a matrix of normalized base counts in a genomic range. TensorFlow allows us to train a neural network that can predict the correct base at the middle position of the window.

图片来源

- 亚历山大·拉什（Alexander Rush）是哈佛大学NLP的研究员，他写了一篇重要的文章，涉及[张量](#)

[问题](#)以及当前的某些库如何暴露它们。他还继续讨论了有关带有命名索引的张量的建议。

ML/NLP工具与数据集

在这里，我重点介绍一些软件和数据集，它们有助于NLP和ML的研究与工程。

- Hugging Face发布了一个流行的基于Pytorch的名称为pytorch-transformers的[Transformer库](#)。它使NLP从业人员和研究人员可以轻松使用最先进的通用体系结构，例如BERT，GPT-2和XLM等。如果您对如何使用pytorch-transformers感兴趣，可以从几个地方开始，但是我很喜欢Roberto Silveira的详细[教程](#)，其中展示了如何使用该库进行机器理解。




Transformers

[原网址](#)

- TensorFlow 2.0已发布，其中包含许多[新功能](#)。在[此处](#)阅读有关最佳实践的更多信息。FrançoisChollet还在一个[Colab notebook](#)对TensorFlow 2.0的新功能进行了广泛的概述。
- PyTorch 1.3发布了许多[新功能](#)，包括命名张量和其他前端改进。
- Allen AI研究院发布了[Iconary](#)，这是一个可以与人类玩Pictionary风格的游戏的AI系统。这项工作结合了视觉/语言学习系统和常识推理。他们还发布了一个新的常识推理[benchmark](#)，称为Abductive-NLI。
- spaCy[发布](#)了一个新库，将Transformer语言模型合并到自己的库中，以便能够提取特征并将其用于spaCy NLP pipelines中。这项工作建立在Hugging Face开发的流行的Transformers库的基础上。Maximilien Roberti还写了一篇不错的[文章](#)，介绍如何将fast.ai代码与pytorch-transformers结合使用。
- Facebook AI团队发布了[PHYRE](#)，这是物理推理的benchmark，旨在通过解决各种物理难题来测试AI系统的物理推理。

PHYRE-B Tier




图片来源

- StanfordNLP发布了[StanfordNLP 0.2.0](#)，这是一个用于自然语言分析的Python库。您可以对70多种不同的语言执行不同类型的语言分析，例如词义化和语音识别。
- [GQA](#)是一个视觉问答数据集，用于进行与视觉推理相关的研究。
- exBERT是一个可视化的交互式工具，用于探索Transformer语言模型的embeddings和attention。您可以在这里找到[论文](#)和[演示](#)。



exBERT -- [原网址](#)

- Distill发表了一篇关于如何可视化递归神经网络（RNN）中记忆的文章。
- [Mathpix](#)是一种工具，可让你为数学方程拍照，然后转换为latex版本。



[原网址](#)


- [Parl.ai](#) 是一个平台，拥有许多流行的数据集，涉及与对话和对话式AI有关的所有工作。
- Uber研究人员发布了 [Ludwig](#)，这是一种开源工具，允许用户仅用几行代码即可轻松训练和测试深度学习模型。整个想法是在训练和测试模型时避免任何代码。
- Google AI研究人员发布了“自然问题 ([Natural Questions](#))”，这是用于训练和评估开放域问题回答系统的大规模语料库。

文章与博客 🖋️

今年见证了数据科学作家和爱好者的爆炸式增长。这对我们的领域非常有益处，并鼓励了健康的讨论和学习。在这里，我列出了一些有趣且必看的文章和博客文章：

- Christian Perone为最大似然估计（MLE）和最大后验（MAP）提供了[出色的介绍](#)，这是了解如何估计模型参数的重要原理。
- 中野礼一郎（Reiichiro Nakano）发表了一篇[博文](#)，讨论了具有对抗性鲁棒分类器的神经网络风格迁移。还提供了一个[Colab notebook](#)。
- 赛义夫·穆罕默德（Saif M. Mohammad）撰写了一系列精彩的[文章](#)，讨论了ACL论文集的历时分析。


Average Academic Age of NLP Researchers



“图表显示平均学术年龄，中位学术年龄和一段时间内AA首次出版商的百分比。” — [原文](#)

- 问题是：语言模型可以学习语法吗？使用结构探针，这项[工作](#)旨在表明可以使用上下文表示法和查找树结构的方法来实现。
- Andrej Karpathy写了一篇[博客文章](#)，总结了最佳实践和如何有效训练神经网络的秘诀。
- Google AI研究人员和其他研究人员[合作](#)，以提高对使用BERT模型的搜索的理解。像BERT这样的上下文方法足以理解搜索查询背后的意图。
- [Rectified Adam](#) (RAdam) 是一种基于Adam优化器的新优化技术，可帮助改善AI架构。为了找到更好、更稳定的优化器，我们付出了许多努力，但作者声称将重点放在优化的其他方面，这些方面对于提供改进的收敛性同样重要。
- 随着近来机器学习工具的大量涌现，关于如何实现能够解决实际问题的机器学习系统的讨论也很多。Chip Huyen写了有趣的[一章](#)，讨论机器学习系统设计，重点是诸如超参数调整（hyperparameter tuning）和数据管道（data pipeline）之类的主题。
- NVIDIA创造了通过数十亿个参数训练的最大语言模型的[记录](#)。
- Abigail See撰写了一篇出色的[博客文章](#)，内容涉及在为执行自然语言生成任务而开发的系统中，如何进行良好的对话。
- Google AI[发布](#)了两个自然语言对话数据集，其想法是使用更复杂和自然的对话数据集来改善数字助手等对话应用程序中的个性化。
- 深度强化学习仍然是AI领域中讨论最广泛的主题之一，它甚至引起了心理学和神经科学领域的兴趣。阅读发表在《认知科学趋势》上的这篇[文章](#)，了解更多有关一些重点内容的信息。

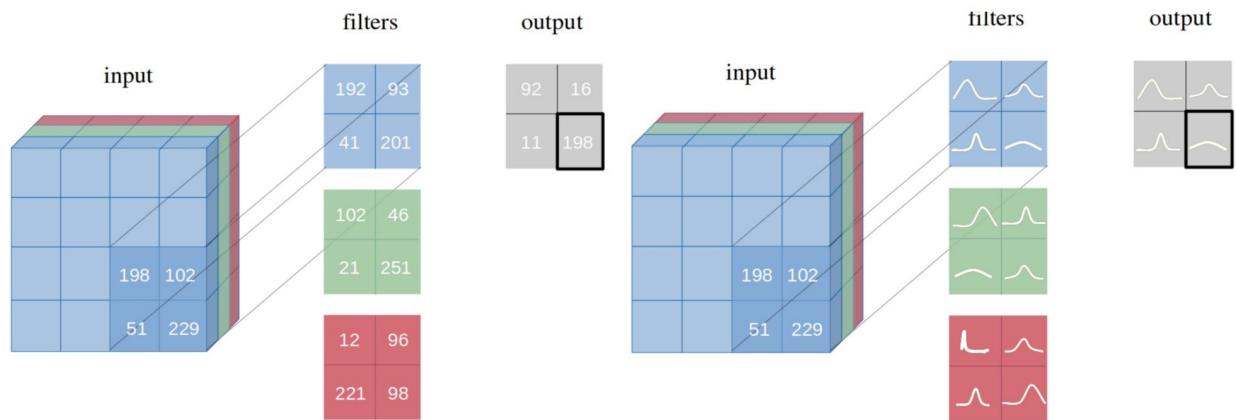
- Samira Abner撰写了一篇出色的[博客文章](#)，总结了Transformers、胶囊网络（capsule networks）及其连接背后的主要构建模块。Adam Kosior还在基于堆栈胶囊的自动编码器（胶囊网络的无监督版本）上写了这幅[文章](#)，该编码器用于物体检测。



Connection between two adjacent capsule layers, where the lower layer has three capsule types and the higher layer has two capsule types.

[图片原网址](#)

- 研究人员在Distill上发表了一篇[互动文章](#)，旨在展示对[高斯过程](#)的视觉探索。
- 通过Distill上的[文章](#)，Augustus Odena呼吁研究人员解决有关GAN的几个重要的开放性问题。
- 这是图卷积网络（GCN）的[PyTorch实现](#)，用于对垃圾邮件发送者和非垃圾邮件发送者进行分类。
- 2019年的年初，VentureBeat发布了由Rumman Chowdury、Hilary Mason、Andrew Ng和Yan LeCun等专家做出的2019年[预测清单](#)。检查一下，看看他们的预测是否正确。
- [了解](#)如何微调（finetune）BERT以执行多标签文本分类。
- 由于BERT的流行，在过去的几个月中，许多研究人员开发了一些方法来“压缩”BERT，其思想是构建更快、更小且内存效率更高的原始版本。Mitchell A. Gordon[总结](#)了围绕此目标开发的压缩类型和方法。
- 超级智能仍然是专家们争论的话题。这是一个重要的主题，需要对框架、策略和仔细观察有正确的理解。我发现这一系列有趣的综合[文章](#)（以K. Eric Drexler的技术报告的形式）对于理解有关超级智能的一些问题和考虑很有用。
- 埃里克·张（Eric Jang）在一篇[博客文章](#)中介绍了元学习的概念，旨在建立和训练不仅预测效果好而且学习效果好的机器学习模型。
- Sebastian Ruder撰写的AAAI 2019重点[总结](#)。
- 图神经网络（graph neural networks）今年受到了广泛的讨论。David Mack撰写了一篇不错的[视觉文章](#)，介绍了他们如何使用此技术并结合attention来执行最短路径计算。
- 贝叶斯（Bayesian）方法仍然是一个有趣的主题，尤其是如何将它们应用于神经网络以避免诸如过拟合（over-fitting）之类的常见问题。这是Kumar Shridhar对该主题的建议[读物清单](#)。



“以点估计为权重的网络 vs 以概率分布为权重的网络” -- [原论文](#)

人工智能伦理

伦理可能是今年人工智能系统中被讨论最多的方面之一，其中包括围绕偏见、公平和透明等方面的讨论。在本节中提供了有关该主题的一些有趣故事和论文的列表：

- 题目为“减轻ML的影响差异是否需要处理差异吗？”的[论文](#)讨论了通过对真实数据集进行的实验应用不同的学习过程的后果。
- HuggingFace发表了一篇[文章](#)，讨论了在对话式AI的开源NLP技术下的道德规范。
- 随着我们继续将基于AI的技术引入社会，能够量化伦理学在AI研究中的作用是一项重要的工作。[本文](#)对这些措施和“在领先的AI、机器学习和机器人技术中，与道德相关的研究的使用”进行了广泛的分析。
- 在NAACL 2019上发表的这项[工作](#)讨论了去偏（debiasing）方法如何隐藏word embeddings中的性别偏见。
- [请观看](#) Zachary Lipton发表的论文“机器学习奖学金的麻烦趋势”。我也写了一篇有趣的论文总结，您可以在[这里](#)找到。
- 加里·马库斯（Gary Marcus）和欧内斯特·戴维斯（Ernest Davis）发表了他们的书“[重启人工智能：建立我们可以信赖的人工智能](#)”。本书的主题是讨论实现鲁棒的人工智能必须采取的步骤。关于AI进步的话题，François Chollet也写了一篇令人印象深刻的[论文](#)，为更好地衡量智能提供了依据。
- 看看安德鲁·特拉斯克（Andrew Trask）创建的有关差异化隐私，联合学习和加密AI等主题的[Udacity课程](#)。关于隐私主题，艾玛·蓝姆克（Emma Blumke）撰写了一篇很棒的[文章](#)，讨论了如何在保护患者隐私的同时如何训练机器学习模型。
- 在今年年初，Mariya Yao发布了一份涉及AI伦理的综合研究论文[摘要清单](#)。尽管论文参考清单来自2018年，但我相信它们今天仍然有意义。

ML/NLP教育

在这里，我将列出一系列教育资源、作者和正在做一些出色工作的人们，向其他人介绍有关ML / NLP困难的概念/主题的知识：

- CMU发布了“[NLP神经网络](#)”课程的材料和课程提纲。
- [Elvis Saravia](#)和[Soujanya Poria](#)发布了一个名为[NLP-Overview](#)的项目，该项目旨在帮助学生和从业者获得应用于NLP的现代深度学习技术的简要概述，包括理论、算法、应用和最新成果-[链接](#)

between the input vectors without making the number of parameters exceptionally large like MV-RNN. RNTN is defined by:

$$p_1 = \tanh \left(\begin{bmatrix} b \\ c \end{bmatrix}^T V^{[1:D]} \begin{bmatrix} b \\ c \end{bmatrix} + W \begin{bmatrix} b \\ c \end{bmatrix} \right)$$

where $V \in \mathcal{R}^{2D \times 2D \times D}$ is a tensor that defines multiple bilinear forms.

B. Applications

One natural application of recursive neural networks is parsing ([Socher et al., 2011](#)). A scoring function is defined on the phrase representation to calculate the plausibility of that phrase. Beam search is usually applied for searching the best tree. The model is trained with the max-margin objective ([Taskar et al., 2004](#)).

Based on recursive neural networks and the parsing tree, [Socher et al. \(2013\)](#) proposed a phrase-level sentiment analysis framework (Figure 19), where each node in the parsing tree can be assigned a sentiment label.

[NLP Overview](#)

- Microsoft Research Lab发布了有关数据科学基础的[免费电子书](#)，其主题从Markov Chain Monte Carlo到Random Graphs。
- “[机器学习数学](#)”是一本免费的电子书，介绍了机器学习中最重要数学概念。它还包括一些描述机器学习部分的Jupyter notebook教程。Jean Gallier和Jocelyn Quaintance撰写了一本[免费电子书](#)，其中涵盖了机器学习中使用的数学概念。
- 斯坦福大学发布“Natural Language Understanding”课程的[视频播放列表](#)。
- 在学习方面，OpenAI汇总了有关如何继续学习和提高机器学习技能的大量[建议](#)。显然，他们的员工每天都使用这些方法来保持学习和扩展知识。

Learning day is a gift ❤️

Feel free to use learning day for:


- Reading AI papers
- Reimplementing AI papers
- Going over AI tutorials
- Having your tiny side research AI projects
- Learning about fundamentals: linear algebra, statistics etc.
- Learning about ML fundamentals: information theory, Bayesian inference etc.
- Learning about engineering. Read about new programming languages, frameworks (e.g. what is Rust?)
- Learning about management: self-management, prioritization, how renowned research labs works (e.g. Manhattan project, Bell labs)
- Learning about mechanical engineering or having your mechanical engineering research project (e.g. build a linear actuator)
- Learning about any skill that will level you up in your work (in my case, it's better writing)

[图片原网址](#)

- Adrian Rosebrock发布了长达81页的[指南](#)，介绍如何使用Python和OpenCV进行计算机视觉。
- 艾米丽·本德（Emily M. Bender）和亚历克斯·拉斯卡里德斯（Alex Lascarides）出版了一本书，标题为“[Linguistic Fundamentals for NLP](#)”。本书的主要思想是通过为语义（semantics）和语用


学 (pragmatics) 提供适当的基础来讨论NLP领域中的“meaning”。

- 埃拉德·哈赞 (Elad Hazan) 在“机器学习的优化”上发表了[他的演讲笔记](#)，旨在将机器训练作为具有数学和符号的优化问题进行介绍。Deeplearning.ai还发表了一篇很棒的[文章](#)，讨论了使用更直观和交互式的方法来优化神经网络中的参数。
- Andreas Mueller发布了“Applied Machine Learning”一门新课程的[视频播放列表](#)。
- Fast.ai发布了其新的[MOOC](#)，标题为“Deep Learning from the Foundations”。
- 麻省理工学院发布了有关“深度学习入门”课程的所有[视频](#)和课程提纲。
- Chip Huyen在推特上发布了一系列令人印象深刻的[免费在线课程](#)，以开始使用机器学习。
- 安德鲁·特拉斯克 (Andrew Trask) 出版了题为“[Grokking深度学习](#)”的书。这本书是理解神经网络体系结构的基本组成部分的一个很好的起点。
- 塞巴斯蒂安·拉施卡 (Sebastian Raschka) 上传了[80份笔记本](#)，介绍了如何实现不同的深度学习模型，如RNN和CNN。很棒的是，所有模型都在PyTorch和TensorFlow中实现。
- 这是一个很棒的[教程](#)，深入了解TensorFlow的工作原理。[这篇](#)是Christian Perone为PyTorch写的。
- Fast.ai还发布了一个名为“NLP简介”的课程，并附带了一个[播放列表](#)。主题范围从情感分析到主题建模再到Transformer。
- 通过Xavier Bresson的演讲，[了解](#)用于分子生成 (Molecular Generation) 的图卷积神经网络 (Graph Convolutional Neural Networks)。幻灯片可以在[这里](#)找到。这是一篇讨论如何预训练GNN的[论文](#)。
- 在图网络的主题上，一些工程师使用它们来[预测分子和晶体的特性](#)。Google AI团队还发表了一篇出色的[博客文章](#)，解释了他们如何使用GNN进行气味预测。如果您对使用Graph Neural Networks感兴趣，这里是各种GNN及其应用的全面[综述](#)。
- 这是有关无监督学习方法的视频的[播放列表](#)，例如约翰·霍普金斯大学的Rene Vidal的PCA。
- 如果您有兴趣将预训练的TensorFlow模型转换为PyTorch，Thomas Wolf在此[博客文章](#)中进行了介绍。
- 想了解生成式深度学习吗？大卫·福斯特 (David Foster) 写了一本[很棒的书](#)，教数据科学家如何应用GAN和编码器-解码器模型执行绘画、写作和音乐创作等任务。这是本书随附的[官方代码库](#)，其中包含TensorFlow代码。还有将这些代码转换为PyTorch的[努力](#)。
- 这是一个包含代码块的[Colab notebook](#)，用于练习和学习因果推理 (causal inference) 概念，例如干预措施、反事实等。
- 这是由Sebastian Ruder, Matthew Peters, Swabha Swayamdipta和Thomas Wolf提供的NAACL 2019教程“Transfer Learning in Natural Language Processing”的[材料](#)。他们还提供了随附的Google Colab [notebook](#)上手。
- Jay Alammar的另一篇很棒的[博客文章](#)，主题是数据表示。他还写了许多其他有趣的插图指南，包括[GPT-2](#)和[BERT](#)。彼得·布洛姆 (Peter Bloem) 还发表了一篇非常详细的[博客文章](#)，解释了构成Transformer的所有要素。



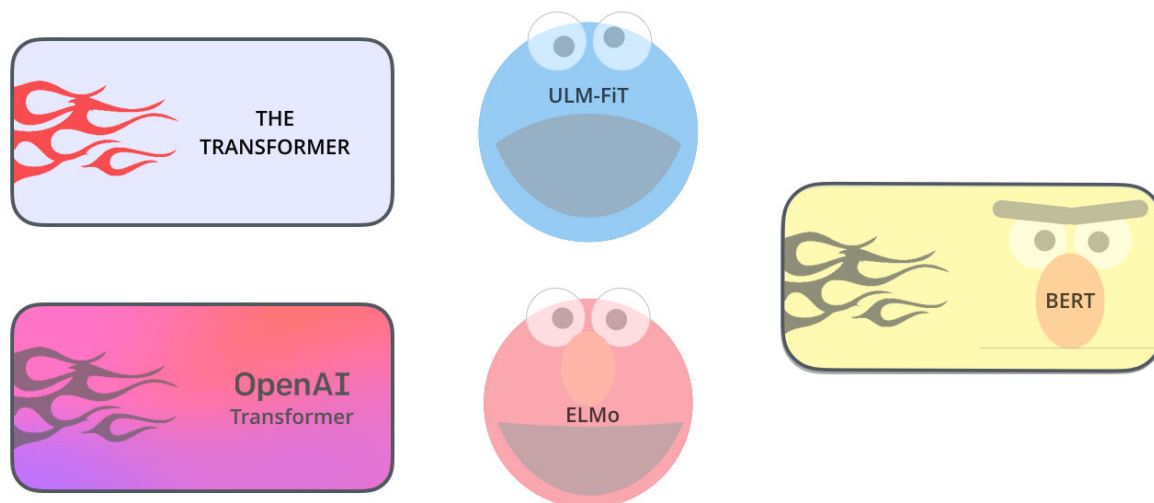
基本self-attention的图示 -- [图片原网址](#)

- 这是Mihail Eric撰写的ACL 2019上NLP趋势的[概述](#)。一些主题包括将知识注入NLP体系结构、可解释性和减少偏见等。如果您有兴趣，这里还有一些概述：[链接2](#)和[链接3](#)。
- 斯坦福大学发布了CS231n 2019版的[完整课程大纲](#)。
- David Abel为ICLR 2019发布了一系列[说明](#)。他也很高兴为NeurIPS 2019提供令人印象深刻的[总结](#)。
- 这是一本非常[出色的书](#)，它为学习者提供了有关带笔记本的深度学习正确介绍。



[图片原网址](#)

- 这是一篇BERT、ELMo和co.的插图指南。



[图片原网址](#)

- Fast.ai发布了其2019版的“面向程序员的实用深度学习”[课程](#)。
- 由Pieter Abbeel和其他人讲授的这门奇妙的[课程](#)，深入了解无监督学习。
- 吉尔伯特·斯特朗（Gilbert Strang）出版了一本有关线性代数和神经网络的[新书](#)。
- 加州理工学院（Caltech）为“[机器学习基础](#)”课程提供了完整的课程提纲、讲义幻灯片和视频播放列表。
- “[Scipy Lecture Notes](#)”是一系列教程，教您如何掌握matplotlib、NumPy和SciPy等工具。
- 这是有关理解高斯过程的优秀[教程](#)，教程提供了notebooks。
- 这是一篇必读的[文章](#)，其中Lilian Weng深入探讨了通用语言模型，例如ULMFit、OpenAI GPT-2

和BERT。

- [Papers with Code](#)是一个网站，显示精选的带有代码和最优结果的机器学习论文列表。
- 克里斯托夫·莫纳尔（Christoph Molnar）发布了第一版“[可解释性机器学习](#)”，该书讲述了用于更好地解释机器学习算法的重要技术。
- 大卫·班曼（David Bamman）发布了伯克利大学（UC Berkley）开设的自然语言处理课程的完整的[课程大纲和幻灯片](#)。
- 伯克利发布其“Applied NLP”课程的所有[资料](#)。
- Aerin Kim是Microsoft的高级研究工程师，[撰写](#)有关应用数学和深度学习文章。主题包括条件独立性、伽马分布、复杂度（perplexity）等。
- Tai-Danae Bradley在此[博文](#)中讨论了如何考虑矩阵和张量的方法。本文以令人难以置信的视觉效果编写，有助于更好地理解在矩阵上执行的某些转换和操作。

a number



a vector



v_i

$$V = \begin{bmatrix} \vdots \\ v_i \\ \vdots \end{bmatrix}$$

a matrix



M_{ij}

$$M = \begin{bmatrix} \vdots & \vdots & \vdots \\ & M_{ij} & \\ \vdots & \vdots & \vdots \end{bmatrix}$$

a 3-tensor



A_{ijk}

$$A = \begin{bmatrix} \vdots & \vdots & \vdots \\ & A_{ijk} & \\ \vdots & \vdots & \vdots \end{bmatrix}$$

a 4-tensor



B_{ijkl}

$$B = \left(\begin{array}{c} 4\text{-dimensional} \\ \text{cube} \dots \end{array} \right)$$

\vdots

\vdots

\vdots

\vdots

[原网址](#)

结语

希望您觉得这些链接有用。祝您2020年成功健康！

由于假期，我没有太多机会对文章进行校对，因此欢迎任何反馈或更正！

>> [英文原文PDF版本](#) <<